Atlântico Avanti

Equipe 3 - Fruit Classification

Alunos:

Fábio Carvalho Simões
Lívia Braga Sydrião de Alencar
Micael José de Lima
Nicolas Kalebe Menezes da Silva
Rafael de Oliveira Feitosa
Yuri Ramos Ribeiro

Sumário

- Introdução
- Metodologia
- Pré-processamento
- Modelos
- Avaliação
- Predição
- Conclusão
- Referências

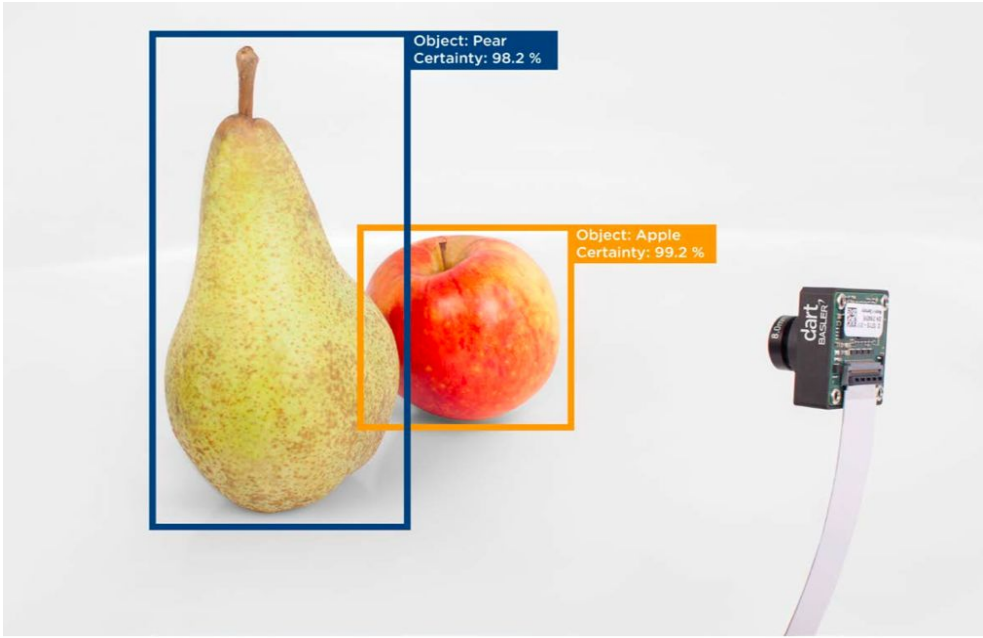

Introdução

- Realização de um projeto de classificação de imagens de diferentes classes de frutas utilizando a biblioteca Tensor Flow.
- Divisão do processo em várias etapas:
  - Pré-processamento dos dados.
  - Exploração das funcionalidades do Tensor Flow.
  - Construção de modelos de aprendizado de máquina.
  - Avaliação dos modelos por diferentes métricas.
  - Predição das imagens.

Introdução

- Importância da classificação automática de imagens de frutas em áreas como:
  - Agricultura.
  - Comércio.
  - Alimentação.
- Desafios da tarefa de classificação:
  - variabilidade nas formas, cores e texturas das frutas.
  - Condições de iluminação e fundo das imagens.
- Importância da solução:
  - Aumento da eficiência e redução dos custos operacionais em setores como agricultura e varejo.
  - Melhoria na qualidade dos produtos entregues ao consumidor.
  - Contribuição para sistemas de monitoramento e análise agrícola, fornecendo dados valiosos para a tomada de decisões.

Metodologia

Base de dados:
Número total de imagens:
22495 imagens

Número de Classes:
33

Tamanho da imagem:
100x100

OBS: Base de dados reduzido

Método:
3 modelos diferentes de CNN

Pré-Processamento

- Verificando valores nulos e duplicatas:
  - Resultado: ok
- Dataframe e Redução do tamanho do dataset:
  - Validação Treinamento e Teste (fração de 88%)
- Carregando imagem e criando um array de dados:
  - Validação Treinamento: (14832, 100, 100, 3)
  - Teste: (4964, 100, 100,3)
- Codificação das classes em valores numéricos
- Divisão de Treinamento, Validação e Teste:
  - Treinamento: (11865, 100, 100, 3) - 80% dos dados
  - Validação: (2967, 100, 100, 3) - 20% dos dados
  - Teste: (4964,100,100,3)
- Aplicação da função prepare:
  - Normalização dos dados (1/ 255)
  - Batch_size = 128
  - suffle = True
  - Augment = True

Modelo 1 - PRINCIPAL

Definição do Modelo CNN:

- Define um modelo sequencial
- Adiciona uma camada convolucional
  - filters = 5
  - kernel_size = 3
  - activation = “relu”
  - input_shape = (100, 100, 3)

- Adiciona uma camada de pooling Máximo
  - pool_size = 2
  - padding = ‘valid’

- Transformação dos dados para camada densa
- Adiciona uma camada densa(totalmente conectada)
  - len(classes)
  - activation = ‘softmax’

Compilação do modelo:

- Configura para treinamento
  - loss = “categorical crossentropy”
  - optimizer= “Adam”
  - metrics = [“Accuracy”]

Modelo 2

Definição do Modelo CNN:

- Define um modelo sequencial
- Adiciona uma camada convolucional
  - filters = 10
  - kernel_size = 5
  - activation = “selu”
  - input_shape = (100, 100, 3)

- Adiciona uma camada de pooling Máximo
  - pool_size = 4
  - padding = ‘same’

- Transformação dos dados para camada densa
- Adiciona uma camada densa(totalmente conectada)
  - len(classes)
  - activation = ‘softmax’

Compilação do modelo:

- Configura para treinamento
  - loss = “categorical crossentropy”
  - optimizer= “SGD”
  - metrics = [“Accuracy”]

Modelo 3

Definição do Modelo CNN:

- Define um modelo sequencial
- Adiciona uma camada convolucional
  - filters = 15
  - kernel_size = 7
  - activation = “leaky_relu”
  - input_shape = (100, 100, 3)

- Adiciona uma camada de pooling Máximo
  - pool_size = 6
  - padding = ‘valid’

- Transformação dos dados para camada densa
- Adiciona uma camada densa(totalmente conectada)
  - len(classes)
  - activation = ‘softmax’

Compilação do modelo:

- Configura para treinamento
  - loss = “categorical crossentropy”
  - optimizer= “Adam”
  - metrics = [“Accuracy”]

Avaliação: Matriz de Confusão - Modelo 1

Cada célula da matriz representa o número de instâncias de uma classe prevista correta ou incorretamente pelo modelo.

$$Precision = \frac{Previsões\ Positivas\ Corretas}{Previsões\ Positivas}$$

$$Recall = \frac{Previsões\ Positivas\ Corretas}{Exemplos\ Positivos}$$

$$F1\ Score = 2 * \frac{Precisão * Recall}{Precisão + Recall}$$

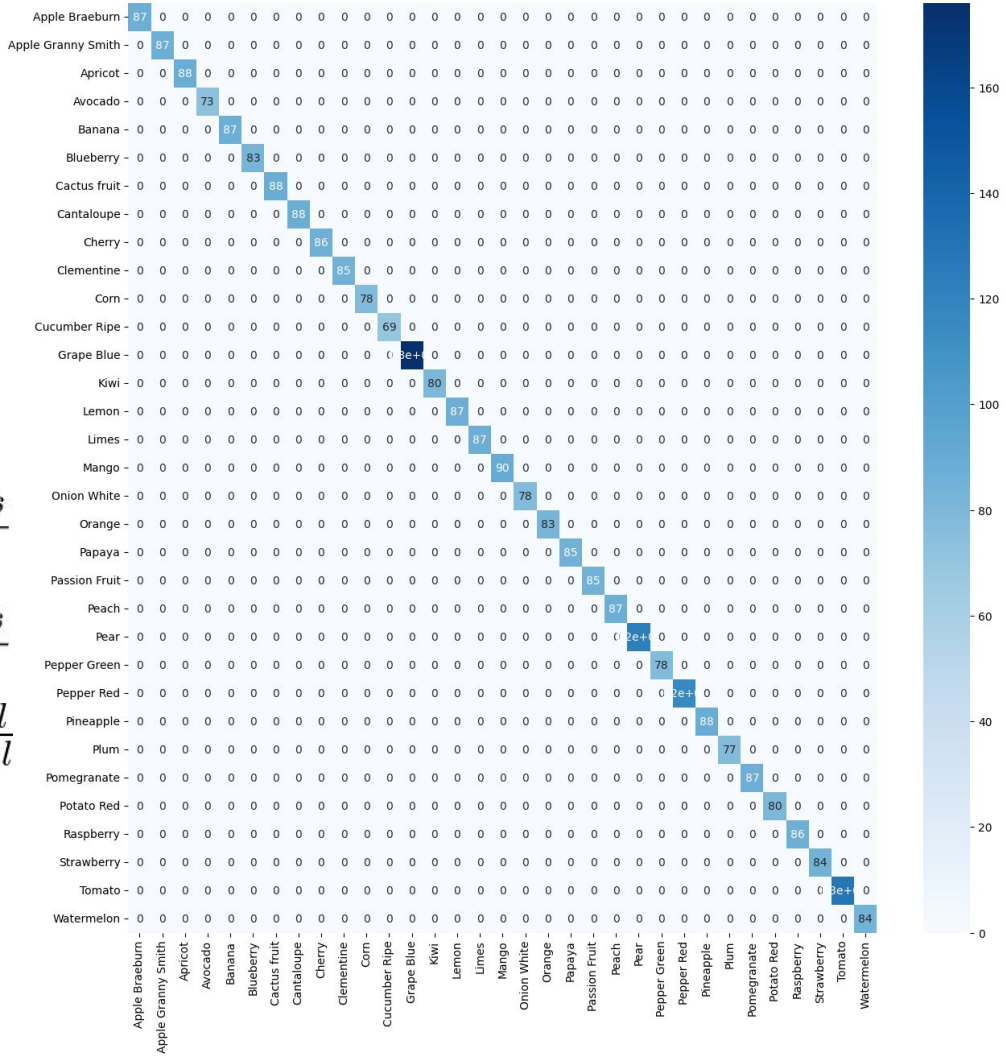

Pontuação:

➪ Precisão: 1.0 ➪ Recall: 1.0 ➪ F1: 1.0

Avaliação: Matriz de Confusão - Modelo 2

Cada célula da matriz representa o número de instâncias de uma classe prevista correta ou incorretamente pelo modelo.

$$Precision = \frac{Previsões\ Positivas\ Corretas}{Previsões\ Positivas}$$

$$Recall = \frac{Previsões\ Positivas\ Corretas}{Exemplos\ Positivos}$$

$$F1\ Score = 2 * \frac{Precisão * Recall}{Precisão + Recall}$$

Pontuação:

➪ Precisão: 0.98 ➪ Recall: 0.99 ➪ F1: 0.98

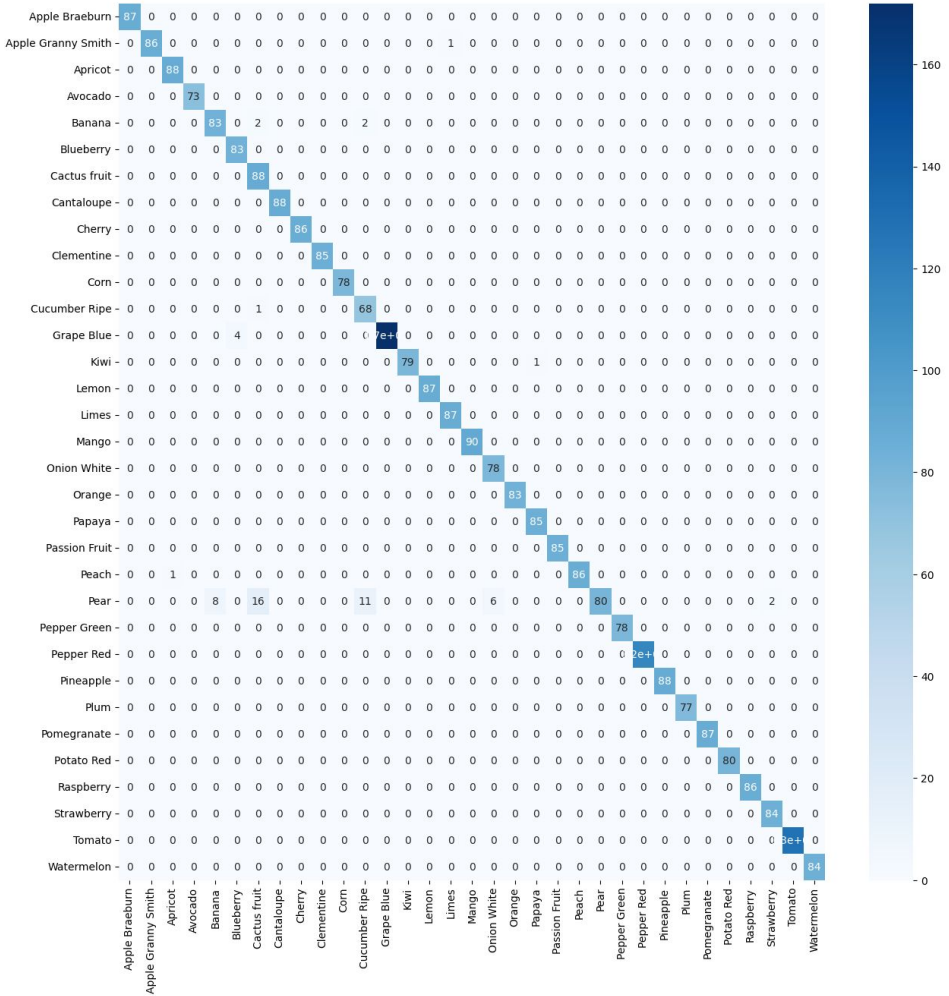

Avaliação: Matriz de Confusão - Modelo 3

Cada célula da matriz representa o número de instâncias de uma classe prevista correta ou incorretamente pelo modelo.

$$Precision = \frac{Previsões\ Positivas\ Corretas}{Previsões\ Positivas}$$

$$Recall = \frac{Previsões\ Positivas\ Corretas}{Exemplos\ Positivos}$$

$$F1\ Score = 2 * \frac{Precisão * Recall}{Precisão + Recall}$$

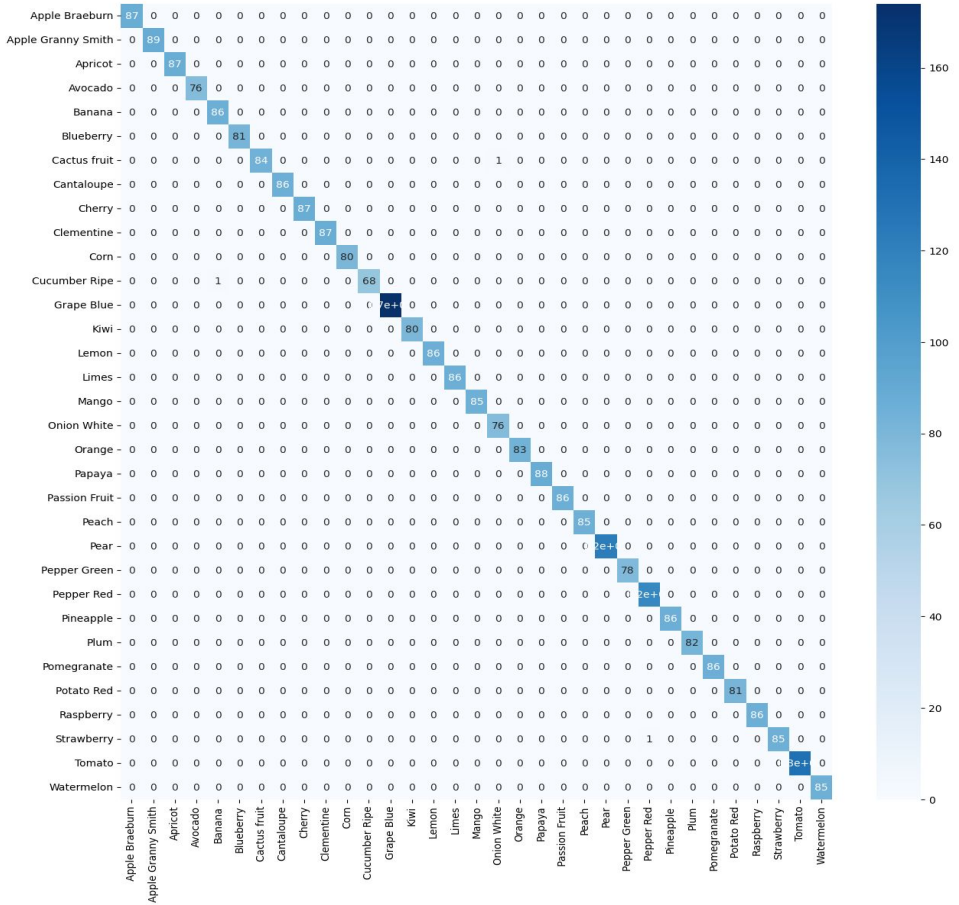

Pontuação:

➪ Precisão: 0.99 ➪ Recall: 0.99 ➪ F1: 0.99

Avaliação: Accuracy x Loss

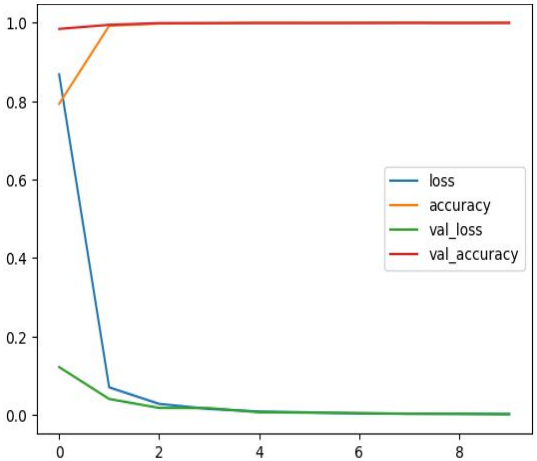

Modelo 1

- 10 epochs
- loss : 0.0
- val_loss: 0.0
- accuracy: 1.0
- val_acurracy: 1.0

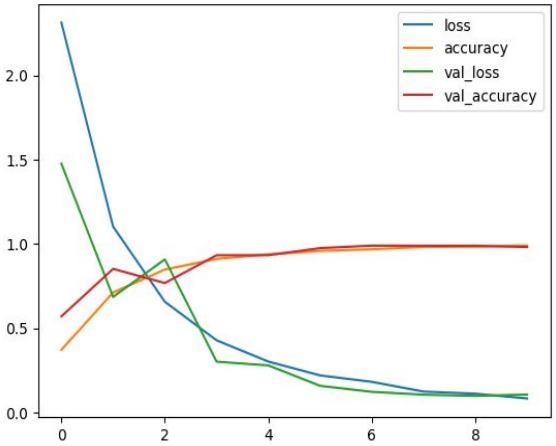

Modelo 2

- 10 epochs
- loss : 0.0
- val_loss: 0.0
- accuracy: 1.0
- val_acurracy: 1.0

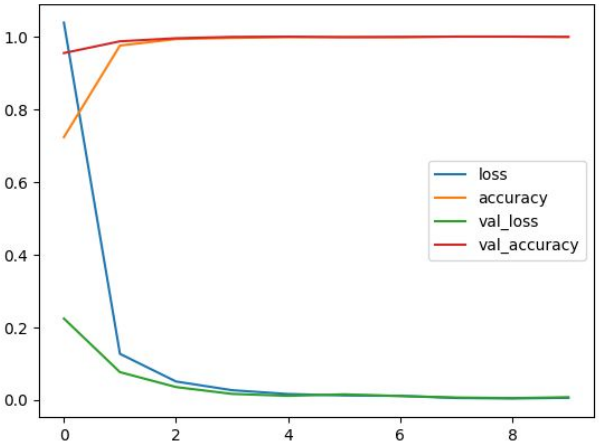

Modelo 3

- 10 epochs
- loss : 0.0
- val_loss: 0.0
- accuracy: 1.0
- val_acurracy: 1.0

Avaliação: TP, FP, FN e TN

	Previsão: Sim	Previsão: Não
Realidade: Sim	Positivo Verdadeiro	Falso Negativo
Realidade: Não	Falso Positivo	Negativo Verdadeiro

- Verdadeiros Positivos (TP)
- Falsos Positivos (FP)
- Falsos Negativos (FN)
- Verdadeiros Negativos (TN)

Modelo 1	**Modelo 2**	**Modelo 2**
➪ TP = 87	➪ TP = 86	➪ TP = 87
➪ FN = 0	➪ FN = 54	➪ FN = 3
➪ FP = 0	➪ FP = 1	➪ FP = 0
➪ TN = 2880	➪ TN = 2881	➪ TN = 2875

Avaliação: Sensibilidade, Especificidade e Média Geométrica

G-mean indica o equilíbrio entre o desempenho na classe majoritária e minoritária e leva em consideração tanto a sensibilidade quanto a especificidade.

- Sensibilidade: Recall
- Especificidade: 1 - (False Positive/ (False Negative + True Negative))
- G-Means = √Sensibilidade * Especificidade

Modelo 1

➪ Sensibilidade = 1.0
➪ Especificidade = 1.0
➪ G-mean = 1.0

Modelo 2

➪ Sensibilidade = 0.61
➪ Especificidade = 0.98
➪ G-mean = 0.77

Modelo 3

➪ Sensibilidade = 0.96
➪ Especificidade = 0.99
➪ G-mean = 0.98

Predição: Modelo 1

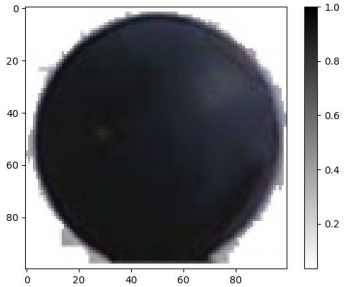

Predição 1

➪ Esperada:
Grape Blue

➪ Predição:
Grape Blue

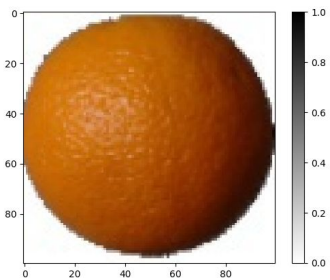

Predição 2

➪ Esperada:
Orange

➪ Predição:
Orange

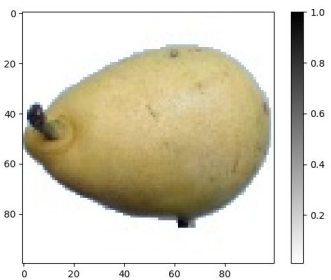

Predição 3

➪ Esperada:
Pear

➪ Predição:
Pear

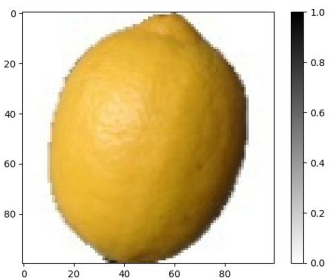

Predição 4

➪ Esperada:
Lemon

➪ Predição:
Lemon

Predição: Modelo 2

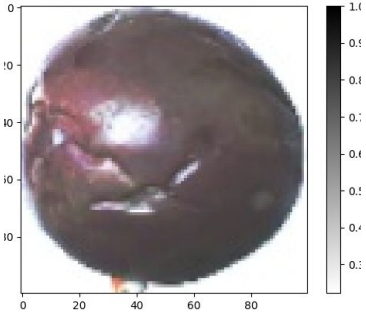

Predição 1

➪ Esperada: Passion Fruit

➪ Predição: Passion Fruit

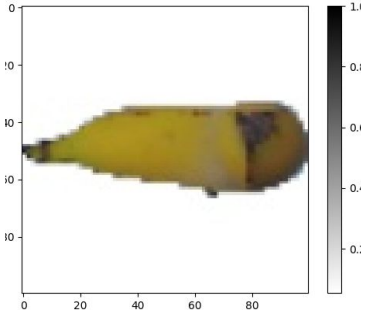

Predição 2

➪ Esperada: Banana

➪ Predição: Banana

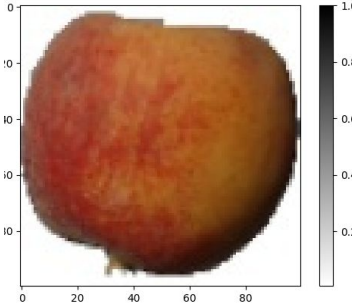

Predição 3

➪ Esperada: Peach

➪ Predição: Peach

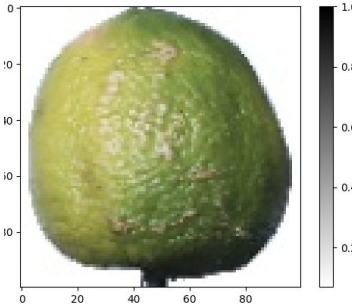

Predição 4

➪ Esperada: Limes

➪ Predição: Limes

Predição: Modelo 3

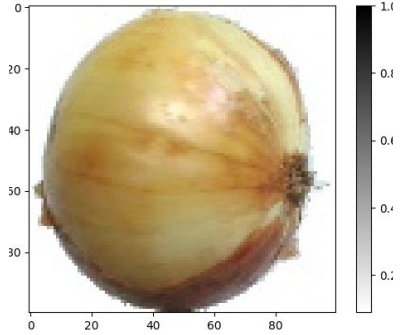

Predição 1

➪ Esperada:
Onion White

➪ Predição:
Onion White

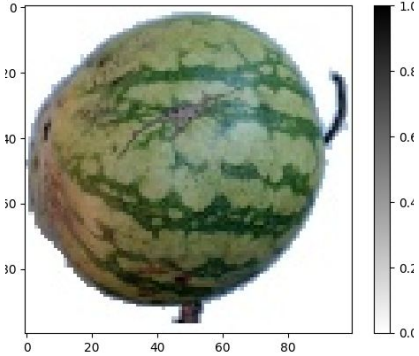

Predição 2

➪ Esperada:
watermelon

➪ Predição:
watermelon

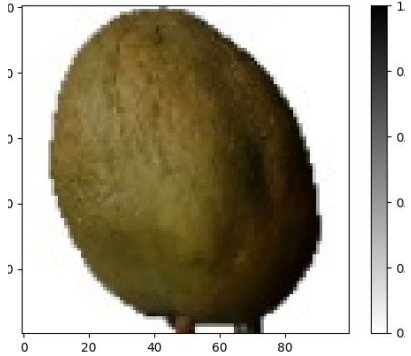

Predição 3

➪ Esperada:
Papaya

➪ Predição:
Papaya

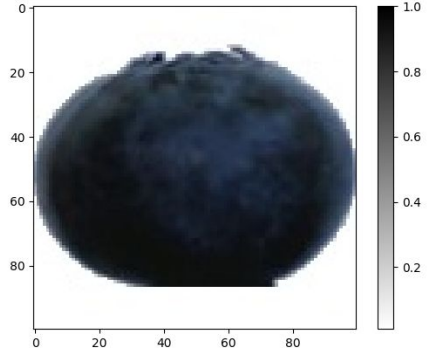

Predição 4

➪ Esperada:
Blueberry

➪ Predição:
Blueberry

Conclusão

- Apesar da mudança dos parâmetros dos 3 modelos, eles continuam obtendo resultados de accuracy, F1-Score, matriz de confusão muito semelhantes.
- O método de Avaliação TP, FP, FN e TN se mostrou o mais efetivo com o método da média geométrica que usa os dados da avaliação anterior que mostra a diferença mais clara entre os modelos 1 que possui 0FN e o modelo 3 que possui 3FN do modelo 2 que possui 54FN o que pode impactar na precisão.
- Provável overffiting dos dados, pelo alto valor de avaliação chegando a 100%, o que de certo modo é algo a desconfiar.
- Não importa as alterações dos parâmetros na construção dos modelos, eles obtem resultados semelhantes , o que significa que pode haver um problema na etapa de pré-processamento.

Conclusão

- Possíveis melhorias:
  - Aumento da base de dados
  - Mudança no formato da imagens
  - Mudança no fundo, iluminação e nas cores das imagens
  - Comparação de características de classes visualmente semelhantes
- Problemas ocorridos:
  - Ambiente de execução limitado para alterações em loop de formatação de cada imagem, ou até aumento destas, o que dificulta melhorias.
  - Adequação às métricas de avaliação, pois sendo dados de imagens multiclasse , há uma limitação de opções em relação a dados tabulares ou de apenas 2 classes.
  - Dificuldade em encontrar os labels do projeto após a divisão dos dados em treino e teste, ao aplicar diferentes métricas de melhoria, avaliação e predição , por necessitar chamar as labels e imagens separadas, como por exemplo a divisão de treino_imagem, treino_labels, teste_imagem e teste_label.

Referências

- https://mariofilho.com/precisao-recall-e-f1-score-em-machine-learning/#qual-a-f%C3%B3rmula-da-precis%C3%A3o-na-matriz-de-confus%C3%A3o
- https://mariofilho.com/as-metricas-mais-populares-para-avaliar-modelos-de-machine-learning/
- https://medium.com/data-hackers/entendendo-o-que-%C3%A9-matriz-de-confus%C3%A3o-com-python-114e683ec509
- https://www.kaggle.com/datasets/sshikamaru/fruit-recognition